


RELATÓRIO TÉCNICO — HEALTHSEARCH

Motor de Busca Híbrido com BM25, Busca Semântica e RRF

1. Objetivo e proposta

O HealthSearch é um protótipo desenvolvido em Python e Streamlit para comparar três estratégias de recuperação de informação em um pequeno corpus médico: busca léxica com Okapi BM25, busca semântica por embeddings e busca híbrida com Reciprocal Rank Fusion (RRF). O objetivo é mostrar que o BM25 é mais preciso para termos e códigos exatos, enquanto a busca semântica consegue lidar melhor com sinônimos e variações de linguagem. O RRF combina os dois rankings para gerar um resultado mais equilibrado.

2. Arquitetura da solução



O corpus possui seis documentos médicos definidos diretamente no código. Para cada consulta, o sistema executa os dois motores de busca em paralelo. O BM25 trabalha com texto normalizado e tokenizado; o motor semântico usa o texto original para gerar vetores. Em seguida, as posições dos dois rankings são combinadas pelo RRF. Como bônus, o Top-3 do ranking híbrido pode passar por um Cross-Encoder para reordenação final.

3. Implementação dos motores

BM25. O pré-processamento converte o texto para minúsculas, remove acentos e caracteres especiais e elimina stopwords em português. A biblioteca rank-bm25 calcula os scores. Os parâmetros k_1 e b são ajustáveis na interface, com valores padrão 1,2 e 0,75.

Busca semântica. A aplicação utiliza o modelo sentence-transformers/distiluse-base-multilingual-cased-v1. Documentos e consulta são transformados em embeddings e comparados por similaridade de cosseno. Se o modelo não puder ser carregado, o sistema utiliza TF-IDF como contingência.

RRF. O método combina as posições obtidas pelo BM25 e pelo motor semântico. O parâmetro α controla o peso de cada lado e a constante k_RRF é 60. Como o RRF usa posições, não é necessário normalizar diretamente os scores dos dois motores.

Cross-Encoder. Quando habilitado, o modelo cross-encoder/ms-marco-MiniLM-L-6-v2 reavalia apenas os três primeiros documentos do RRF, permitindo comparar o ranking híbrido antes e depois do re-ranking.

4. Interface e comparação dos resultados

A interface concentra os controles na barra lateral. O usuário informa a consulta, ajusta k_1 , b e α e pode ativar o Cross-Encoder. Os resultados são exibidos em abas separadas para facilitar a comparação entre o ranking léxico, o semântico, o híbrido e a matriz comparativa. A aplicação também apresenta informações de desempenho e permite visualizar o corpus utilizado.

Resumo das diferenças entre os métodos:

Critério	BM25	Semântico	RRF
Termos/códigos exatos	Muito bom	Pode variar	Mantém influência léxica
Sinônimos/contexto	Limitado	Muito bom	Combina os dois
Tipo de score	Relevância léxica	Cosseno	Posição combinada

5. Tecnologias e execução

Tecnologias principais: Python, Streamlit, Pandas, NumPy, rank-bm25, scikit-learn e sentence-transformers.

Para executar o projeto:

```
python -m pip install -r requirements.txt
python -m streamlit run healthsearch_app.py
```

6. Resultados e limitações

Os testes do projeto mostraram que o modelo `distiluse-base-multilingual-cased-v1` apresentou melhor comportamento no corpus para consultas semânticas usadas na avaliação interna, principalmente nos casos em que a consulta utiliza sinônimos. O BM25 continua sendo importante para códigos como CÓD-ECG-12D. A combinação por RRF permite aproveitar os dois comportamentos sem misturar diretamente escalas de score diferentes.

A principal limitação é o tamanho reduzido do corpus, composto por apenas seis documentos. Além disso, o modo TF-IDF usado como contingência não substitui uma busca semântica real, e o Cross-Encoder adotado foi treinado principalmente em inglês, o que limita a interpretação dos seus valores absolutos em textos em português.

7. Participação da equipe

O desenvolvimento foi realizado de forma colaborativa por Ewellyn Maria de França O. Andrade, Gustavo Palmeira de A. Martinez e Rafael Cirne Medeiros, envolvendo implementação dos motores de busca, integração da interface, testes e revisão da solução.

8. Conclusão

O HealthSearch atende ao objetivo de demonstrar, em uma única aplicação, as diferenças entre busca léxica, semântica e híbrida. O projeto evidencia que não existe um único método ideal para todos os tipos de consulta: o BM25 preserva precisão em correspondências exatas, os embeddings ampliam a recuperação por significado e o RRF reúne essas duas perspectivas em um ranking único. O Cross-Encoder acrescenta uma etapa opcional de refinamento dos melhores resultados.